

# Optimización Numérica sin restricciones

## Tema 4: Algoritmos Cuasi-Newton

Oscar Dalmau

Centro de Investigación en Matemáticas  
CIMAT

11 de mayo de 2021

# Orden del Tema

## 1 Introducción

## 2 Algoritmos Cuasi-Newton

Corrección de rango 1. Symmetric rank 1 (SR1)

Corrección de rango 2. Davidon-Fletcher-Powell (DFP)

Algoritmo DFP usando aproximación del Hessiano

Algoritmo BFGS

Algoritmo L-BFGS

## Introducción: Algoritmo de Newton

- El método de Newton es un algoritmo iterativo que permite obtener el óptimo  $\mathbf{x}^*$  de una función 2 veces continuamente diferenciable  $f : \mathbb{R}^n \rightarrow \mathbb{R}$ .
- Es un algoritmo de optimización sin restricciones
- A partir de un punto inicial  $\mathbf{x}_0$  se genera una secuencia  $\{\mathbf{x}_k\}$

$$\mathbf{x}_{k+1} = \mathbf{x}_k - (\nabla^2 f_k)^{-1} \nabla f_k$$

donde  $\nabla^2 f_k = \nabla^2 f(\mathbf{x}_k)$  es el Hessiano y  $\nabla f_k = \nabla f(\mathbf{x}_k)$  es el gradiente

# Introducción

- Para encontrar el nuevo punto  $\mathbf{x}_{k+1}$  a partir de  $\mathbf{x}_k$ , se define  $\mathbf{d} = \mathbf{x} - \mathbf{x}_k$  y se usa una aproximación de Taylor de segundo orden de la función

$$m_k(\mathbf{d}) = f_k + \nabla^T f_k \mathbf{d} + \frac{1}{2} \mathbf{d}^T \nabla^2 f_k \mathbf{d}$$

- El tamaño de paso  $p$  se obtiene calculando el gradiente, igualando a cero y resolviendo para  $p$

$$\nabla f_k + \nabla^2 f_k \mathbf{d} = 0$$

$$\mathbf{d} = -(\nabla^2 f_k)^{-1} \nabla f_k$$

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha_k (\nabla^2 f_k)^{-1} \nabla f_k, \quad \alpha_k = 1$$

# Introducción

- Para encontrar el nuevo punto  $\mathbf{x}_{k+1}$  a partir de  $\mathbf{x}_k$ , se define  $\mathbf{d} = \mathbf{x} - \mathbf{x}_k$  y se usa una aproximación de Taylor de segundo orden de la función

$$m_k(\mathbf{d}) = f_k + \nabla^T f_k \mathbf{d} + \frac{1}{2} \mathbf{d}^T \nabla^2 f_k \mathbf{d}$$

- El tamaño de paso  $p$  se obtiene calculando el gradiente, igualando a cero y resolviendo para  $p$

$$\nabla f_k + \nabla^2 f_k \mathbf{d} = 0$$

$$\mathbf{d} = -(\nabla^2 f_k)^{-1} \nabla f_k$$

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha_k (\nabla^2 f_k)^{-1} \nabla f_k, \quad \alpha_k = 1$$

# Introducción

- Una de la problemáticas del método de Newton es que requiere calcular el Hessiano  $\nabla^2 f_k$  el cual puerder ser muy costoso
- Más aún, requiere del cálculo de la inversa del Hessiano

$$d_k = -(\nabla^2 f_k)^{-1} \nabla f_k$$

- Otro problema es que no se puede garantizar que  $d_k$  sea una dirección de descenso, i.e, puede suceder que  $d_k^T \nabla f_k = -\nabla^T f_k (\nabla^2 f_k)^{-1} \nabla f_k > 0$  en alguna o varias iteraciones ..., por ejemplo, si  $\nabla^2 f_k$  es definida negativa.

# Introducción

- Una alternativa de solución, cuando  $d_k$  no es una dirección de descenso, es modificar el Hessiano añadiendo una matrix  $\mathbf{E}_k$  de modo que la nueva matriz  $\mathbf{B}_k = \nabla^2 f_k + \mathbf{E}_k$  sea definida positiva. En ejemplo trivial, sería hacer  $\mathbf{E}_k$  un múltiplo de la matriz idéntica  $\mathbf{E}_k = \tau \mathbf{I}$ . La nueva dirección de descenso sería

$$d = -\mathbf{B}_k^{-1} \nabla f_k$$

- La alternativa anterior garantiza que la dirección  $d_k$  sea de descenso, sin embargo, requiere del cálculo de Hessiano. Además necesita de un algoritmo que garantice que la nueva matriz  $\mathbf{B}_k$  sea definida positiva (p.e. Cholesky).
- Existe alguna otra alternativa??

# Introducción

- Una alternativa de solución, cuando  $d_k$  no es una dirección de descenso, es modificar el Hessiano añadiendo una matrix  $\mathbf{E}_k$  de modo que la nueva matriz  $\mathbf{B}_k = \nabla^2 f_k + \mathbf{E}_k$  sea definida positiva. En ejemplo trivial, sería hacer  $\mathbf{E}_k$  un múltiplo de la matriz idéntica  $\mathbf{E}_k = \tau \mathbf{I}$ . La nueva dirección de descenso sería

$$d = -\mathbf{B}_k^{-1} \nabla f_k$$

- La alternativa anterior garantiza que la dirección  $d_k$  sea de descenso, sin embargo, requiere del cálculo de Hessiano. Además necesita de un algoritmo que garantice que la nueva matriz  $\mathbf{B}_k$  sea definida positiva (p.e. Cholesky).
- Existe alguna otra alternativa??



# Introducción

- Una alternativa de solución, cuando  $d_k$  no es una dirección de descenso, es modificar el Hessiano añadiendo una matrix  $\mathbf{E}_k$  de modo que la nueva matriz  $\mathbf{B}_k = \nabla^2 f_k + \mathbf{E}_k$  sea definida positiva. En ejemplo trivial, sería hacer  $\mathbf{E}_k$  un múltiplo de la matriz idéntica  $\mathbf{E}_k = \tau \mathbf{I}$ . La nueva dirección de descenso sería

$$d = -\mathbf{B}_k^{-1} \nabla f_k$$

- La alternativa anterior garantiza que la dirección  $d_k$  sea de descenso, sin embargo, requiere del cálculo de Hessiano. Además necesita de un algoritmo que garantice que la nueva matriz  $\mathbf{B}_k$  sea definida positiva (p.e. Cholesky).
- Existe alguna otra alternativa??

# Introducción

- Los métodos cuasi-newton construyen un modelo que se basa en medir los cambios del gradiente.
- Solo requieren del cálculo del gradiente, similar al algoritmo de máximo descenso.
- Su comportamiento es superior al algoritmo de máximo descenso.
- En lugar de calcular el Hessiano en cada iteración se propone un método que permite calcular una secuencia  $\mathbf{B}_k$  usando la curvatura medida en el paso actual.

# Introducción

- El primer algoritmo Cuasi-Newton fue propuesto por Davidson en 1959, luego fue estudiado por Fletcher and Powell, y es conocido como el *Algoritmo DFP* en honor a sus trabajos.
- Una mejora del algoritmo *DFP* se obtuvo independientemente por Broyden, Fletcher, Goldfarb y Shanno por eso es conocido como el *Algoritmo BFGS*

# Orden del Tema

## 1 Introducción

## 2 Algoritmos Cuasi-Newton

Corrección de rango 1. Symmetric rank 1 (SR1)

Corrección de rango 2. Davidon-Fletcher-Powell (DFP)

Algoritmo DFP usando aproximación del Hessiano

Algoritmo BFGS

Algoritmo L-BFGS

## Recordatorio

En el problema cuadrático

$$\min f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{Q} \mathbf{x} - \mathbf{b}^T \mathbf{x}$$

donde  $\mathbf{Q}^T = \mathbf{Q}$ , al usar la actualización de descenso

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha \mathbf{d}_k$$

Por otro lado

$$\mathbf{g}_{k+1} = \mathbf{Q} \mathbf{x}_{k+1} - \mathbf{b}$$

$$\mathbf{g}_k = \mathbf{Q} \mathbf{x}_k - \mathbf{b}$$

se llega a la conclusión

$$\mathbf{Q}(\mathbf{x}_{k+1} - \mathbf{x}_k) = \mathbf{g}_{k+1} - \mathbf{g}_k$$

# Recordatorio

Definiendo  $y_k = g_{k+1} - g_k$  y  $s_k = x_{k+1} - x_k$  se tiene la relación

$$Qs_k = y_k$$

que se conoce como **ecuación de la secante**. Podemos escribir también

$$Q^{-1}y_k = s_k$$

## Idea General

Para el problema general

$$\text{mín } f(\mathbf{x})$$

La idea de los métodos Cuasi-Newton es usar una aproximación del método de Newton

$$\begin{aligned}\mathbf{x}_{k+1} &= \mathbf{x}_k - \mathbf{B}_k^{-1} \mathbf{g}_k \\ \mathbf{x}_{k+1} &= \mathbf{x}_k - \mathbf{H}_k \mathbf{g}_k\end{aligned}$$

donde  $\mathbf{B}_k \approx \nabla^2 f_k$  o  $\mathbf{H}_k \approx \nabla^2 f_k^{-1}$ .

## Idea General

Que se obtienen de minimizar alguno de los modelos

$$m_{k+1}(\mathbf{d}) = f_{k+1} + \nabla^T f_{k+1} \mathbf{d} + \frac{1}{2} \mathbf{d}^T \mathbf{B}_{k+1} \mathbf{d}$$

$$m_{k+1}(\mathbf{d}) = f_{k+1} + \nabla^T f_{k+1} \mathbf{d} + \frac{1}{2} \mathbf{d}^T \mathbf{H}_{k+1}^{-1} \mathbf{d}$$

donde  $\mathbf{B}_k \approx \nabla^2 f_k$  o  $\mathbf{H}_k \approx \nabla^2 f_k^{-1}$ .



## Idea General

Para determinar las matrices anteriores se imponen algunas condiciones a las matrices  $\mathbf{B}_{k+1}$  o  $\mathbf{H}_{k+1}$ .

Por ejemplo se pide que sean simétricas y satisfagan la ecuación de la secante, ie

$$\mathbf{B}_{k+1} \mathbf{s}_k = \mathbf{y}_k$$

$$\mathbf{H}_{k+1} \mathbf{y}_k = \mathbf{s}_k$$

## Symmetric rank 1

A partir de ahora vamos a aproximar la inversa del Hessiano, ie,  $\mathbf{H}_k \approx \nabla^2 f_k^{-1}$ .

La idea es construir una secuencia  $\mathbf{H}_0, \mathbf{H}_1, \dots$  que satisfaga,

$$\mathbf{H}_{k+1} \mathbf{y}_i = \mathbf{s}_i, i = 0, 1, \dots k$$

## Symmetric rank 1

La corrección de rango 1 se puede escribir como sigue

$$\mathbf{H}_{k+1} = \mathbf{H}_k + \alpha \mathbf{x} \mathbf{x}^T$$

## Symmetric rank 1

Luego

$$\begin{aligned}\mathbf{H}_{k+1}\mathbf{y}_k &= \mathbf{H}_k\mathbf{y}_k + \alpha\mathbf{x}\mathbf{x}^T\mathbf{y}_k \\ \alpha\mathbf{x}(\mathbf{x}^T\mathbf{y}_k) &= \mathbf{s}_k - \mathbf{H}_k\mathbf{y}_k \\ \mathbf{x} &= \frac{\mathbf{s}_k - \mathbf{H}_k\mathbf{y}_k}{\alpha\mathbf{x}^T\mathbf{y}_k}\end{aligned}$$

y por tanto

$$\mathbf{H}_{k+1} = \mathbf{H}_k + \frac{(\mathbf{s}_k - \mathbf{H}_k\mathbf{y}_k)(\mathbf{s}_k - \mathbf{H}_k\mathbf{y}_k)^T}{\alpha(\mathbf{x}^T\mathbf{y}_k)^2}$$

cuanto es  $\alpha(\mathbf{x}^T\mathbf{y}_k)^2$ ?

## Symmetric rank 1

De la igualdad  $\alpha \mathbf{x}(\mathbf{x}^T \mathbf{y}_k) = \mathbf{s}_k - \mathbf{H}_k \mathbf{y}_k$  se tiene

$$\begin{aligned}\alpha \mathbf{x}(\mathbf{x}^T \mathbf{y}_k) &= \mathbf{s}_k - \mathbf{H}_k \mathbf{y}_k \\ \alpha \mathbf{y}_k^T \mathbf{x}(\mathbf{x}^T \mathbf{y}_k) &= \mathbf{y}_k^T (\mathbf{s}_k - \mathbf{H}_k \mathbf{y}_k) \\ \alpha (\mathbf{x}^T \mathbf{y}_k)^2 &= \mathbf{y}_k^T (\mathbf{s}_k - \mathbf{H}_k \mathbf{y}_k)\end{aligned}$$

Por lo que finalmente se tiene

$$\mathbf{H}_{k+1}^{SR1} = \mathbf{H}_k + \frac{(\mathbf{s}_k - \mathbf{H}_k \mathbf{y}_k)(\mathbf{s}_k - \mathbf{H}_k \mathbf{y}_k)^T}{\mathbf{y}_k^T (\mathbf{s}_k - \mathbf{H}_k \mathbf{y}_k)}$$

# Orden del Tema

## 1 Introducción

## 2 Algoritmos Cuasi-Newton

Corrección de rango 1. Symmetric rank 1 (SR1)

**Corrección de rango 2. Davidon-Fletcher-Powell (DFP)**

Algoritmo DFP usando aproximación del Hessiano

Algoritmo BFGS

Algoritmo L-BFGS

## Symmetric rank 2

La corrección de rango 2 se puede escribir como sigue

$$\mathbf{H}_{k+1} = \mathbf{H}_k + \alpha \mathbf{x} \mathbf{x}^T + \beta \mathbf{y} \mathbf{y}^T$$

satisfaciendo

$$\mathbf{H}_{k+1} \mathbf{y}_k = \mathbf{s}_k$$

## Symmetric rank 2

Luego

$$\begin{aligned}\mathbf{H}_{k+1}\mathbf{y}_k &= \mathbf{H}_k\mathbf{y}_k + \alpha\mathbf{x}\mathbf{x}^T\mathbf{y}_k + \beta\mathbf{y}\mathbf{y}^T\mathbf{y}_k \\ \alpha\mathbf{x}(\mathbf{x}^T\mathbf{y}_k) + \beta\mathbf{y}(\mathbf{y}^T\mathbf{y}_k) &= \mathbf{s}_k - \mathbf{H}_k\mathbf{y}_k \\ \alpha(\mathbf{x}^T\mathbf{y}_k)\mathbf{x} + \beta(\mathbf{y}^T\mathbf{y}_k)\mathbf{y} &= \mathbf{s}_k - \mathbf{H}_k\mathbf{y}_k\end{aligned}$$

La ecuación anterior tiene infinitas soluciones, por lo que podemos tomar o podemos definir convenientemente

$$\begin{aligned}\mathbf{x} &= \mathbf{s}_k \\ \mathbf{y} &= \mathbf{H}_k\mathbf{y}_k\end{aligned}$$



## Symmetric rank 2

$$[\alpha(\mathbf{x}^T \mathbf{y}_k)] \mathbf{s}_k + [\beta(\mathbf{y}^T \mathbf{y}_k)] \mathbf{H}_k \mathbf{y}_k = \mathbf{s}_k - \mathbf{H}_k \mathbf{y}_k$$

Luego se toma

$$\begin{aligned}\alpha(\mathbf{x}^T \mathbf{y}_k) &= 1 \\ \beta(\mathbf{y}^T \mathbf{y}_k) &= -1\end{aligned}$$

es decir

$$\begin{aligned}\alpha &= \frac{1}{\mathbf{x}^T \mathbf{y}_k} = \frac{1}{\mathbf{s}_k^T \mathbf{y}_k} \\ \beta &= -\frac{1}{\mathbf{y}^T \mathbf{y}_k} = -\frac{1}{\mathbf{y}_k^T \mathbf{H}_k \mathbf{y}_k}\end{aligned}$$

## Symmetric rank 2

Finalmente se tiene

$$\mathbf{H}_{k+1}^{DFP} = \mathbf{H}_k + \frac{\mathbf{s}_k \mathbf{s}_k^T}{\mathbf{s}_k^T \mathbf{y}_k} - \frac{\mathbf{H}_k \mathbf{y}_k \mathbf{y}_k^T \mathbf{H}_k}{\mathbf{y}_k^T \mathbf{H}_k \mathbf{y}_k}$$

# Algoritmo DFP: aproximando la inversa del Hessiano

---

## Algorithm 1 DFP

---

**Require:**  $x_0$  y  $H_0$

**Ensure:**  $x^*$

- 1:  $k = 0$
  - 2: **while**  $\|\nabla f_k\| \neq 0$  (No conveja) **do**
  - 3:    $d_k = -H_k \nabla f_k$
  - 4:   Calcular  $\alpha_k$  usando búsqueda en línea.
  - 5:    $x_{k+1} = x_k + \alpha_k d_k$
  - 6:   Calcular  $\nabla f_{k+1}$ ,  $y_k$ ,  $s_k$  y actualizar  $H_{k+1}$   
      
$$H_{k+1} = H_k - \frac{H_k y_k y_k^T H_k}{y_k^T H_k y_k} + \frac{s_k s_k^T}{y_k^T s_k}$$
  - 7:    $k = k + 1$
  - 8: **end while**
-

# Orden del Tema

## 1 Introducción

## 2 Algoritmos Cuasi-Newton

Corrección de rango 1. Symmetric rank 1 (SR1)

Corrección de rango 2. Davidon-Fletcher-Powell (DFP)

**Algoritmo DFP usando aproximación del Hessiano**

Algoritmo BFGS

Algoritmo L-BFGS

## DFP usando aproximación del Hessiano

Se tiene

$$\mathbf{H}_{k+1} = \mathbf{H}_k - \frac{\mathbf{H}_k \mathbf{y}_k \mathbf{y}_k^T \mathbf{H}_k}{\mathbf{y}_k^T \mathbf{H}_k \mathbf{y}_k} + \frac{\mathbf{s}_k \mathbf{s}_k^T}{\mathbf{s}_k^T \mathbf{y}_k}$$

Definamos  $\mathbf{U}$ ,  $\mathbf{V}$ ,  $a$  y  $b$  y eliminemos los índices por comodidad

$$\begin{aligned}\mathbf{U} &= [a\mathbf{s}, b\mathbf{H}\mathbf{y}] \\ \mathbf{V} &= \begin{bmatrix} a\mathbf{s}^T \\ -b\mathbf{y}^T \mathbf{H} \end{bmatrix} \\ a^2 &= \frac{1}{\mathbf{y}^T \mathbf{s}} \\ b^2 &= \frac{1}{\mathbf{y}^T \mathbf{H} \mathbf{y}}\end{aligned}$$

## DFP usando aproximación del Hessiano

Nota que

$$\begin{aligned}\mathbf{UV} &= [\mathbf{a}\mathbf{s}, \mathbf{b}\mathbf{H}\mathbf{y}] \begin{bmatrix} \mathbf{a}\mathbf{s}^T \\ -\mathbf{b}\mathbf{y}^T\mathbf{H} \end{bmatrix} \\ &= \mathbf{a}^2\mathbf{s}\mathbf{s}^T - \mathbf{b}^2\mathbf{H}\mathbf{y}\mathbf{y}^T\mathbf{H} \\ &= \frac{\mathbf{s}\mathbf{s}^T}{\mathbf{y}^T\mathbf{s}} - \frac{\mathbf{H}\mathbf{y}\mathbf{y}^T\mathbf{H}}{\mathbf{y}^T\mathbf{H}\mathbf{y}}\end{aligned}$$

## DFP usando aproximación del Hessiano

Luego podemos escribir

$$\begin{aligned}\mathbf{H}_{k+1} &= \mathbf{H}_k - \frac{\mathbf{H}_k \mathbf{y}_k \mathbf{y}_k^T \mathbf{H}_k}{\mathbf{y}_k^T \mathbf{H}_k \mathbf{y}_k} + \frac{\mathbf{s}_k \mathbf{s}_k^T}{\mathbf{y}_k^T \mathbf{s}_k} \\ &= \mathbf{H}_k + \mathbf{U}_k \mathbf{V}_k\end{aligned}$$

Apliquemos la formula de Sherman-Morrison-Woodbury

$$(\mathbf{A} + \mathbf{UV})^{-1} = \mathbf{A}^{-1} - \mathbf{A}^{-1} \mathbf{U} (\mathbf{I} + \mathbf{VA}^{-1} \mathbf{U})^{-1} \mathbf{VA}^{-1}$$

## DFP usando aproximación del Hessiano

Como  $\mathbf{B} = \mathbf{H}^{-1}$ , ie,  $\mathbf{B}\mathbf{H} = \mathbf{I}$

$$\begin{aligned}(\mathbf{H} + \mathbf{U}\mathbf{V})^{-1} &= \mathbf{H}^{-1} - \mathbf{H}^{-1}\mathbf{U} (\mathbf{I} + \mathbf{V}\mathbf{H}^{-1}\mathbf{U})^{-1} \mathbf{V}\mathbf{H}^{-1} \\ &= \mathbf{B} - \mathbf{B}\mathbf{U} (\mathbf{I} + \mathbf{V}\mathbf{B}\mathbf{U})^{-1} \mathbf{V}\mathbf{B}\end{aligned}$$

Primero calculemos  $\mathbf{V}\mathbf{B}\mathbf{U}$  y luego  $(\mathbf{I} + \mathbf{V}\mathbf{B}\mathbf{U})^{-1}$



## DFP usando aproximación del Hessiano

$$\begin{aligned}\mathbf{VBU} &= \begin{bmatrix} a\mathbf{s}^T \\ -b\mathbf{y}^T \mathbf{H} \end{bmatrix} \mathbf{B}[a\mathbf{s}, b\mathbf{H}\mathbf{y}] \\ &= \begin{bmatrix} a\mathbf{s}^T \\ -b\mathbf{y}^T \mathbf{H} \end{bmatrix} [a\mathbf{B}\mathbf{s}, b\mathbf{B}\mathbf{H}\mathbf{y}] \\ &= \begin{bmatrix} a^2\mathbf{s}^T \mathbf{B}\mathbf{s} & abs^T \mathbf{B}\mathbf{H}\mathbf{y} \\ -aby^T \mathbf{H}\mathbf{B}\mathbf{s} & -b^2\mathbf{y}^T \mathbf{H}\mathbf{B}\mathbf{H}\mathbf{y} \end{bmatrix} \\ &= \begin{bmatrix} a^2\mathbf{s}^T \mathbf{B}\mathbf{s} & abs^T \mathbf{y} \\ -aby^T \mathbf{s} & -b^2\mathbf{y}^T \mathbf{H}\mathbf{y} \end{bmatrix} \\ &= \begin{bmatrix} a^2\mathbf{s}^T \mathbf{B}\mathbf{s} & abs^T \mathbf{y} \\ -aby^T \mathbf{s} & -1 \end{bmatrix}\end{aligned}$$

## DFP usando aproximación del Hessiano

$$\begin{aligned}\mathbf{I} + \mathbf{VBU} &= \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} + \begin{bmatrix} a^2 \mathbf{s}^T \mathbf{B} \mathbf{s} & ab \mathbf{s}^T \mathbf{y} \\ -ab \mathbf{y}^T \mathbf{s} & -1 \end{bmatrix} \\ &= \begin{bmatrix} a^2 \mathbf{s}^T \mathbf{B} \mathbf{s} + 1 & ab \mathbf{s}^T \mathbf{y} \\ -ab \mathbf{y}^T \mathbf{s} & 0 \end{bmatrix}\end{aligned}$$

Luego

$$(\mathbf{I} + \mathbf{VBU})^{-1} = \frac{1}{(ab)^2 (\mathbf{y}^T \mathbf{s})^2} \begin{bmatrix} 0 & -ab \mathbf{s}^T \mathbf{y} \\ ab \mathbf{y}^T \mathbf{s} & a^2 \mathbf{s}^T \mathbf{B} \mathbf{s} + 1 \end{bmatrix}$$

## DFP usando aproximación del Hessiano

$$\begin{aligned}
 & \mathbf{U}(\mathbf{I} + \mathbf{VBU})^{-1}\mathbf{V} \\
 = & \frac{1}{(ab)^2(\mathbf{y}^T \mathbf{s})^2} [a\mathbf{s}, b\mathbf{H}\mathbf{y}] \begin{bmatrix} 0 & -ab\mathbf{y}^T \mathbf{s} \\ ab\mathbf{y}^T \mathbf{s} & a^2 \mathbf{s}^T \mathbf{B} \mathbf{s} + 1 \end{bmatrix} \begin{bmatrix} a\mathbf{s}^T \\ -b\mathbf{y}^T \mathbf{H} \end{bmatrix} \\
 = & \frac{1}{(ab)^2(\mathbf{y}^T \mathbf{s})^2} [a\mathbf{s}, b\mathbf{H}\mathbf{y}] \begin{bmatrix} ab^2 \mathbf{y}^T \mathbf{s} \mathbf{y}^T \mathbf{H} \\ a^2 b \mathbf{y}^T \mathbf{s} \mathbf{s}^T - b(a^2 \mathbf{s}^T \mathbf{B} \mathbf{s} + 1) \mathbf{y}^T \mathbf{H} \end{bmatrix} \\
 = & \frac{a^2 \mathbf{b}^2 \mathbf{y}^T \mathbf{s} \mathbf{s} \mathbf{y}^T \mathbf{H} + a^2 \mathbf{b}^2 \mathbf{y}^T \mathbf{s} \mathbf{H} \mathbf{y} \mathbf{s}^T - \mathbf{b}^2 (a^2 \mathbf{s}^T \mathbf{B} \mathbf{s} + 1) \mathbf{H} \mathbf{y} \mathbf{y}^T \mathbf{H}}{a^2 \mathbf{b}^2 (\mathbf{y}^T \mathbf{s})^2} \\
 = & \frac{a^2 \mathbf{y}^T \mathbf{s} \mathbf{H} \mathbf{y} \mathbf{s}^T + a^2 \mathbf{y}^T \mathbf{s} \mathbf{s} \mathbf{y}^T \mathbf{H} - (a^2 \mathbf{s}^T \mathbf{B} \mathbf{s} + 1) \mathbf{H} \mathbf{y} \mathbf{y}^T \mathbf{H}}{\mathbf{y}^T \mathbf{s}} \\
 = & a^2 \mathbf{H} \mathbf{y} \mathbf{s}^T + a^2 \mathbf{s} \mathbf{y}^T \mathbf{H} - \frac{(a^2 \mathbf{s}^T \mathbf{B} \mathbf{s} + 1) \mathbf{H} \mathbf{y} \mathbf{y}^T \mathbf{H}}{\mathbf{y}^T \mathbf{s}}
 \end{aligned}$$

## DFP usando aproximación del Hessiano

Como  $\rho = a^2 = \frac{1}{\mathbf{y}^T \mathbf{s}}$  entonces

$$\mathbf{U}(\mathbf{I} + \mathbf{VBU})^{-1}\mathbf{V} = \rho \mathbf{H} \mathbf{y} \mathbf{s}^T + \rho \mathbf{s} \mathbf{y}^T \mathbf{H} - \rho(\rho \mathbf{s}^T \mathbf{B} \mathbf{s} + 1) \mathbf{H} \mathbf{y} \mathbf{y}^T \mathbf{H}$$

Luego

$$\begin{aligned} & \mathbf{BU}(\mathbf{I} + \mathbf{VBU})^{-1}\mathbf{VB} \\ &= \rho \mathbf{B} \mathbf{H} \mathbf{y} \mathbf{s}^T \mathbf{B} + \rho \mathbf{B} \mathbf{s} \mathbf{y}^T \mathbf{H} \mathbf{B} - \rho(\rho \mathbf{s}^T \mathbf{B} \mathbf{s} + 1) \mathbf{B} \mathbf{H} \mathbf{y} \mathbf{y}^T \mathbf{H} \mathbf{B} \\ &= \rho \mathbf{y} \mathbf{s}^T \mathbf{B} + \rho \mathbf{B} \mathbf{s} \mathbf{y}^T - \rho(\rho \mathbf{s}^T \mathbf{B} \mathbf{s} + 1) \mathbf{y} \mathbf{y}^T \end{aligned}$$

## DFP usando aproximación del Hessiano

$$\begin{aligned} & (\mathbf{H} + \mathbf{UV})^{-1} \\ &= \mathbf{B} - \mathbf{BU}(\mathbf{I} + \mathbf{VBU})^{-1}\mathbf{VB} \\ &= \mathbf{B} - \rho \mathbf{y} \mathbf{s}^T \mathbf{B} - \rho \mathbf{B} \mathbf{s} \mathbf{y}^T + \rho^2 \mathbf{s}^T \mathbf{B} \mathbf{s} \mathbf{y} \mathbf{y}^T + \rho \mathbf{y} \mathbf{y}^T \\ &= \mathbf{B} - \rho \mathbf{y} \mathbf{s}^T \mathbf{B} - \rho \mathbf{B} \mathbf{s} \mathbf{y}^T + \rho^2 \mathbf{y} \mathbf{s}^T \mathbf{B} \mathbf{s} \mathbf{y}^T + \rho \mathbf{y} \mathbf{y}^T \\ &= (\mathbf{I} - \rho \mathbf{y} \mathbf{s}^T) \mathbf{B} - (\mathbf{I} - \rho \mathbf{y} \mathbf{s}^T) \rho \mathbf{B} \mathbf{s} \mathbf{y}^T + \rho \mathbf{y} \mathbf{y}^T \\ &= (\mathbf{I} - \rho \mathbf{y} \mathbf{s}^T) \mathbf{B} - (\mathbf{I} - \rho \mathbf{y} \mathbf{s}^T) \rho \mathbf{B} \mathbf{s} \mathbf{y}^T + \rho \mathbf{y} \mathbf{y}^T \\ &= (\mathbf{I} - \rho \mathbf{y} \mathbf{s}^T) (\mathbf{B} - \rho \mathbf{B} \mathbf{s} \mathbf{y}^T) + \rho \mathbf{y} \mathbf{y}^T \\ &= (\mathbf{I} - \rho \mathbf{y} \mathbf{s}^T) \mathbf{B} (\mathbf{I} - \rho \mathbf{s} \mathbf{y}^T) + \rho \mathbf{y} \mathbf{y}^T \end{aligned}$$

## DFP usando aproximación del Hessiano

Finalmente, incluyendo los subíndices

$$\mathbf{B}_{k+1} = (\mathbf{I} - \rho_k \mathbf{y}_k \mathbf{s}_k^T) \mathbf{B}_k (\mathbf{I} - \rho_k \mathbf{s}_k \mathbf{y}_k^T) + \rho_k \mathbf{y}_k \mathbf{y}_k^T$$

$$\text{con } \rho_k = \frac{1}{\mathbf{y}_k^T \mathbf{s}_k}$$

Note que  $\mathbf{B}_{k+1} \succ 0$  siempre que  $\mathbf{B}_k \succ 0$ ,  $\rho_k > 0$  y no se halla llegado a la solución, esto último significa que  $\mathbf{y}_k \neq 0$ . Para ello, se puede verificar que  $\mathbf{x}^T \mathbf{B}_{k+1} \mathbf{x} > 0$  para todo  $\mathbf{x} \neq 0$ . Una idea es considerar los casos  $\mathbf{x}^T \mathbf{y}_k = 0$  y  $\mathbf{x}^T \mathbf{y}_k \neq 0$

## DFP usando aproximación del Hessiano

En resumen, para Davidon-Fletcher-Powell (DFP) se cumple

$$\mathbf{H}_{k+1}^{DFP} = \mathbf{H}_k - \frac{\mathbf{H}_k \mathbf{y}_k \mathbf{y}_k^T \mathbf{H}_k}{\mathbf{y}_k^T \mathbf{H}_k \mathbf{y}_k} + \frac{\mathbf{s}_k \mathbf{s}_k^T}{\mathbf{y}_k^T \mathbf{s}_k}$$

Usando la formula de Sherman-Morrison-Woodbury

$$\mathbf{B}_{k+1}^{DFP} = (\mathbf{I} - \rho_k \mathbf{y}_k \mathbf{s}_k^T) \mathbf{B}_k (\mathbf{I} - \rho_k \mathbf{s}_k \mathbf{y}_k^T) + \rho_k \mathbf{y}_k \mathbf{y}_k^T$$

## DFP- aproximando el Hessiano

---

### Algorithm 2 DFP- aproximando el Hessiano

---

**Require:**  $x_0$  y  $B_0$

**Ensure:**  $x^*$

- 1:  $k = 0$
  - 2: **while**  $\|\nabla f_k\| \neq 0$  (No conveja) **do**
  - 3:    $d_k = -B_k^{-1} \nabla f_k$
  - 4:   Calcular  $\alpha_k$  usando búsqueda en línea.
  - 5:    $x_{k+1} = x_k + \alpha_k d_k$
  - 6:   Calcular  $\nabla f_{k+1}$ ,  $y_k$ ,  $s_k$ ,  $\rho_k$  y actualizar  $B_{k+1}$   
      
$$B_{k+1} = (I - \rho_k y_k s_k^T) B_k (I - \rho_k s_k y_k^T) + \rho_k y_k y_k^T$$
  - 7:    $k = k + 1$
  - 8: **end while**
-



# Algoritmo DFP

---

## Algorithm 3 DFP- aproximando la inversa del Hessiano

---

**Require:**  $x_0$  y  $H_0$

**Ensure:**  $x^*$

- 1:  $k = 0$
  - 2: **while**  $\|\nabla f_k\| \neq 0$  (No conveja) **do**
  - 3:    $d_k = -H_k \nabla f_k$
  - 4:   Calcular  $\alpha_k$  usando búsqueda en línea.
  - 5:    $x_{k+1} = x_k + \alpha_k d_k$
  - 6:   Calcular  $\nabla f_{k+1}$ ,  $y_k$ ,  $s_k$  y actualizar  $H_{k+1}$   
      
$$H_{k+1} = H_k - \frac{H_k y_k y_k^T H_k}{y_k^T H_k y_k} + \frac{s_k s_k^T}{y_k^T s_k}$$
  - 7:    $k = k + 1$
  - 8: **end while**
-

# Orden del Tema

## 1 Introducción

## 2 Algoritmos Cuasi-Newton

Corrección de rango 1. Symmetric rank 1 (SR1)

Corrección de rango 2. Davidon-Fletcher-Powell (DFP)

Algoritmo DFP usando aproximación del Hessiano

**Algoritmo BFGS**

Algoritmo L-BFGS

## Algoritmo BFGS

- En el BFGS la idea es calcular la aproximación de matriz inversa del Hessiano  $\mathbf{H}_{k+1}$  basado en  $\mathbf{B}_{k+1}$
- Para ello se considera la ecuación DFP, con  $\rho_k = \frac{1}{\mathbf{s}_k^T \mathbf{y}_k}$

$$\mathbf{B}_{k+1} = (\mathbf{I} - \rho_k \mathbf{y}_k \mathbf{s}_k^T) \mathbf{B}_k (\mathbf{I} - \rho_k \mathbf{s}_k \mathbf{y}_k^T) + \rho_k \mathbf{y}_k \mathbf{y}_k^T$$

y las relaciones

$$\begin{array}{ccc} \mathbf{B}_{k+1} \mathbf{s}_k & = & \mathbf{y}_k \\ \updownarrow & & \updownarrow \\ \mathbf{H}_{k+1} \mathbf{y}_k & = & \mathbf{s}_k \end{array}$$

Ahora  $\rho_k = \frac{1}{\mathbf{y}_k^T \mathbf{s}_k}$  y por tanto:

$$\mathbf{H}_{k+1} = (\mathbf{I} - \rho_k \mathbf{s}_k \mathbf{y}_k^T) \mathbf{H}_k (\mathbf{I} - \rho_k \mathbf{y}_k \mathbf{s}_k^T) + \rho_k \mathbf{s}_k \mathbf{s}_k^T$$

# Algoritmo BFGS

---

## Algorithm 4 Algoritmo BFGS

---

**Require:**  $x_0$  y  $H_0$

**Ensure:**  $x^*$

- 1:  $k = 0$
  - 2: **while**  $\|\nabla f_k\| \neq 0$  (No conveja) **do**
  - 3:    $d_k = -H_k \nabla f_k$
  - 4:   Calcular  $\alpha_k$  usando búsqueda en línea.
  - 5:    $x_{k+1} = x_k + \alpha_k d_k$
  - 6:   Calcular  $\nabla f_{k+1}$ ,  $y_k$ ,  $s_k$ ,  $\rho_k$  y actualizar  $H_{k+1}$   
       $H_{k+1} = (I - \rho_k s_k y_k^T) H_k (I - \rho_k y_k s_k^T) + \rho_k s_k s_k^T$
  - 7:    $k = k + 1$
  - 8: **end while**
-

## BFGS aproximación del Hessiano

$$\begin{aligned}\mathbf{H}_{k+1}^{DFP} &= \mathbf{H}_k - \frac{\mathbf{H}_k \mathbf{y}_k \mathbf{y}_k^T \mathbf{H}_k}{\mathbf{y}_k^T \mathbf{H}_k \mathbf{y}_k} + \frac{\mathbf{s}_k \mathbf{s}_k^T}{\mathbf{y}_k^T \mathbf{s}_k} \\ \mathbf{B}_{k+1}^{BFGS} &= \mathbf{B}_k - \frac{\mathbf{B}_k \mathbf{s}_k \mathbf{s}_k^T \mathbf{B}_k}{\mathbf{s}_k^T \mathbf{B}_k \mathbf{s}_k} + \frac{\mathbf{y}_k \mathbf{y}_k^T}{\mathbf{s}_k^T \mathbf{y}_k}\end{aligned}$$

## DFP vs BFGS

En resumen

$$\mathbf{H}_{k+1}^{DFP} = \mathbf{H}_k - \frac{\mathbf{H}_k \mathbf{y}_k \mathbf{y}_k^T \mathbf{H}_k}{\mathbf{y}_k^T \mathbf{H}_k \mathbf{y}_k} + \frac{\mathbf{s}_k \mathbf{s}_k^T}{\mathbf{y}_k^T \mathbf{s}_k}$$

$$\mathbf{B}_{k+1}^{BFGS} = \mathbf{B}_k - \frac{\mathbf{B}_k \mathbf{s}_k \mathbf{s}_k^T \mathbf{B}_k}{\mathbf{s}_k^T \mathbf{B}_k \mathbf{s}_k} + \frac{\mathbf{y}_k \mathbf{y}_k^T}{\mathbf{s}_k^T \mathbf{y}_k}$$

$$\begin{aligned}\mathbf{B}_{k+1}^{DFP} &= (\mathbf{I} - \rho_k \mathbf{y}_k \mathbf{s}_k^T) \mathbf{B}_k (\mathbf{I} - \rho_k \mathbf{s}_k \mathbf{y}_k^T) + \rho_k \mathbf{y}_k \mathbf{y}_k^T \\ \mathbf{H}_{k+1}^{BFGS} &= (\mathbf{I} - \rho_k \mathbf{s}_k \mathbf{y}_k^T) \mathbf{H}_k (\mathbf{I} - \rho_k \mathbf{y}_k \mathbf{s}_k^T) + \rho_k \mathbf{s}_k \mathbf{s}_k^T\end{aligned}$$

Si el tamaño de paso cumple las condiciones de Wolfe con  $0 < c_2 < 1$ , y si  $\nabla f_k \neq 0$ , entonces

$$\begin{aligned}
 \nabla f_{k+1}^T \mathbf{d}_k &\geq c_2 \nabla f_k^T \mathbf{d}_k \\
 \nabla f_{k+1}^T \alpha_k \mathbf{d}_k &\geq c_2 \nabla f_k^T \alpha_k \mathbf{d}_k \\
 \mathbf{g}_{k+1}^T \mathbf{s}_k &\geq c_2 \mathbf{g}_k^T \mathbf{s}_k \\
 \mathbf{g}_{k+1}^T \mathbf{s}_k - \mathbf{g}_k^T \mathbf{s}_k &\geq c_2 \mathbf{g}_k^T \mathbf{s}_k - \mathbf{g}_k^T \mathbf{s}_k \\
 \mathbf{y}_k^T \mathbf{s}_k &\geq (c_2 - 1) \mathbf{g}_k^T \mathbf{s}_k \\
 \mathbf{y}_k^T \mathbf{s}_k &\geq \underbrace{(c_2 - 1)}_{<0} \overbrace{\alpha_k}^{>0} \underbrace{\mathbf{g}_k^T \mathbf{d}_k}_{<0}
 \end{aligned}$$

Luego

$$\mathbf{y}_k^T \mathbf{s}_k \geq (c_2 - 1) \alpha_k \mathbf{g}_k^T \mathbf{d}_k > 0$$

por tanto  $\rho_k > 0$  y  $\mathbf{H}_{k+1}$  es definida positiva.





# Orden del Tema

## 1 Introducción

## 2 Algoritmos Cuasi-Newton

Corrección de rango 1. Symmetric rank 1 (SR1)  
Corrección de rango 2. Davidon-Fletcher-Powell (DFP)  
Algoritmo DFP usando aproximación del Hessiano  
Algoritmo BFGS  
Algoritmo L-BFGS

## Algoritmo L-BFGS

- El algoritmo BGFS es presenta un buen desempeño y no requiere el cálculo del Hessiano ni de su inversa.
- La principal limitación del algoritmo BFGS es en problemas donde el número de variable es muy grande (por ejemplo, un millón de variables o mas) pues es casi imposible guardar la matriz de tamaño  $n \times n$ .
- Una solución a problemas de *gran escala* es el algoritmo **L-BFGS** ('Limited memory BFGS').

## Algoritmo L-BFGS

- **Observación 1:** La matriz

$$\mathbf{H}_k = (\mathbf{I} - \rho_{k-1} \mathbf{s}_{k-1} \mathbf{y}_{k-1}^T) \mathbf{H}_{k-1} (\mathbf{I} - \rho_{k-1} \mathbf{y}_{k-1} \mathbf{s}_{k-1}^T) + \rho_{k-1} \mathbf{s}_{k-1} \mathbf{s}_{k-1}^T$$

se actualiza usando matrices de rango 1, i.e.,

$$\begin{aligned} & \mathbf{s}_{k-1} \mathbf{s}_{k-1}^T, \\ \mathbf{V}_{k-1} &= \mathbf{I} - \rho_{k-1} \mathbf{y}_{k-1} \mathbf{s}_{k-1}^T, \\ \mathbf{V}_{k-1}^T &= \mathbf{I} - \rho_{k-1} \mathbf{s}_{k-1} \mathbf{y}_{k-1}^T. \end{aligned}$$

## Algoritmo L-BFGS

- **Observación 2:** Para resolver el problema de optimización, lo que se requiere es calcular el paso  $\mathbf{d}_k = -\mathbf{H}_k \nabla f_k$
- Es decir, en la práctica no es interés conocer  $\mathbf{H}_k$  sino el producto  $\mathbf{H}_k \nabla f_k$
- **Observación 3:** De

$$\mathbf{H}_k \nabla f_k = \mathbf{V}_{k-1}^T \mathbf{H}_{k-1} \mathbf{V}_{k-1} \nabla f_k + \rho_{k-1} \mathbf{s}_{k-1} (\mathbf{s}_{k-1}^T \nabla f_k)$$

donde  $\mathbf{V}_{k-1} \nabla f_k = \nabla f_k - \rho_{k-1} \mathbf{y}_{k-1} (\mathbf{s}_{k-1}^T \nabla f_k)$  y  $\rho_{k-1} \mathbf{s}_{k-1} (\mathbf{s}_{k-1}^T \nabla f_k)$  son vectores, y las operaciones son sumas y productos interiores.

## Algoritmo L-BFGS

- La ecuación del Hessiano se puede reescribir, sustituyendo  $\mathbf{H}_{k-1}$  por su ecuación en función de  $\mathbf{H}_{k-2}$

$$\begin{aligned}\mathbf{H}_k = & (\mathbf{V}_{k-1}^T \mathbf{V}_{k-2}^T) \mathbf{H}_{k-2} (\mathbf{V}_{k-1} \mathbf{V}_{k-2}) \\ & + \mathbf{V}_{k-1}^T \mathbf{s}_{k-2} \rho_{k-2} \mathbf{s}_{k-2}^T \mathbf{V}_{k-1} + \mathbf{s}_{k-1} \rho_{k-1} \mathbf{s}_{k-1}^T\end{aligned}$$

- En azul y rojo son vectores o matrices donde el cálculo solo involucra productos interiores.
- En verde aparece la matriz  $\mathbf{H}_{k-2}$  y otras operaciones matriciales.

## Algoritmo L-BFGS

- Al multiplicar por  $\nabla f_k$

$$\begin{aligned}\mathbf{H}_k \nabla f_k &= (\mathbf{V}_{k-1}^T \mathbf{V}_{k-2}^T) \mathbf{H}_{k-2} (\mathbf{V}_{k-1} \mathbf{V}_{k-2}) \nabla f_k \\ &\quad + \mathbf{V}_{k-1}^T \mathbf{s}_{k-2} \rho_{k-2} \mathbf{s}_{k-2}^T \mathbf{V}_{k-1} \nabla f_k \\ &\quad + \mathbf{s}_{k-1} \rho_{k-1} \mathbf{s}_{k-1}^T \nabla f_k\end{aligned}$$

- En azul son vectores, y su cálculo solo involucra productos interiores.
- En rojo el producto resultante es un número real y su cálculo solo involucra productos interiores.
- En verde aparece la matriz  $\mathbf{H}_{k-2}$  y otras operaciones matriciales.

## Algoritmo L-BFGS

- Continuado el proceso

$$\begin{aligned}
 \mathbf{H}_k = & (\mathbf{V}_{-1}^T \mathbf{V}_{-2}^T \cdots \mathbf{V}_{-m}^T) \mathbf{H}_{-m}^0 (\mathbf{V}_{-1} \mathbf{V}_{-2} \cdots \mathbf{V}_{-m}) \\
 & + (\mathbf{V}_{-1}^T \mathbf{V}_{-2}^T \cdots \mathbf{V}_{-m+1}^T) \mathbf{s}_{-m} \rho_{-m} \mathbf{s}_{-m}^T (\mathbf{V}_{-1} \mathbf{V}_{-2} \cdots \mathbf{V}_{-m+1}) \\
 & + (\mathbf{V}_{-1}^T \mathbf{V}_{-2}^T \cdots \mathbf{V}_{-m+2}^T) \mathbf{s}_{-m+1} \rho_{-m+1} \mathbf{s}_{-m+1}^T (\mathbf{V}_{-1} \mathbf{V}_{-2} \cdots \mathbf{V}_{-m+2}) \\
 & \dots \\
 & + \mathbf{V}_{-1}^T \mathbf{s}_{-2} \rho_{-2} \mathbf{s}_{-2}^T \mathbf{V}_{-1} \\
 & + \mathbf{s}_{-1} \rho_{-1} \mathbf{s}_{-1}^T
 \end{aligned}$$

**Nota:** para el índice  $k - i$  se usa  $-i$  y  $\mathbf{H}_{-m}^0 = \mathbf{H}_{k-m}$

## Algoritmo L-BFGS

- $\mathbf{H}_{-m}^0$  juega el papel de  $\mathbf{H}_0$  en el BFGS y es como si en lugar de iniciar en  $\mathbf{x}_0$  hubiéramos iniciado en  $\mathbf{x}_{-m}$ .
- En problema en el algoritmo anterior es que se requiere calcular  $\mathbf{H}_{-m}^0 \mathbf{q}$ , y no queremos guardar  $\mathbf{H}_{-m}^0$ .
- Para ello se toma  $\mathbf{H}_{-m}^0$  usando una forma simple, por ejemplo, un múltiplo de la matriz identidad.
- En la práctica  $\mathbf{H}_{-m}^0 = \gamma_k \mathbf{I}$  con  $\gamma_k = \frac{\mathbf{s}_{k-1}^T \mathbf{y}_{k-1}}{\mathbf{y}_{k-1}^T \mathbf{y}_{k-1}}$  ha mostrado buenos resultados.



## Algoritmo L-BFGS

- El cálculo de  $\mathbf{H}_k \nabla f_k$  se puede realizar guardando, por ejemplo,  $m$  pareja de vectores  $\{s_i, y_i\}$  anteriores
- El cálculo se realiza a través de productos interiores y sumas.
- Para la siguiente iteración se guarda la última pareja  $\{s_k, y_k\}$  y se remueve la primera.
- Notar que se gana en cuanto a memoria, sin embargo, aumenta el tiempo de cómputo!!!.

## Algoritmo L-BFGS

---

### Algorithm 5 Algoritmo para calcular el paso L-BFGS

---

**Require:**  $\nabla f_k$ ,  $\mathbf{s}_{-i}$ ,  $\mathbf{y}_{-i}$  para  $i = 1, \dots, m$

**Ensure:**  $\mathbf{r}$

```
1:  $\mathbf{q} = \nabla f_k$ 
2: for ( $i = 1 \dots m$ ) do
3:    $\alpha_i = \rho_{-i} \mathbf{s}_{-i}^T \mathbf{q}$ 
4:    $\mathbf{q} = \mathbf{q} - \alpha_i \mathbf{y}_{-i}$ 
5: end for
6:  $\mathbf{r} = \mathbf{H}_{-m}^0 \mathbf{q}$ 
7: for ( $i = m \dots 1$ ) do
8:    $\beta = \rho_{-i} \mathbf{y}_{-i}^T \mathbf{r}$ 
9:    $\mathbf{r} = \mathbf{r} + \mathbf{s}_{-i} (\alpha_i - \beta)$ 
10: end for
```

---

## Algoritmo L-BFGS

Por qué trabaja?

- Sea  $\mathbf{q}_i$  el valor de  $\mathbf{q}$  después de la  $i$ -ésima iteración del primer ciclo y  $\mathbf{q}_0 = \nabla f_k$ . De acuerdo al algoritmo

$$\begin{aligned}\mathbf{q}_i &= \mathbf{q}_{i-1} - \rho_{-i} \mathbf{y}_{-i} \mathbf{s}_{-i}^T \mathbf{q}_{i-1} = \mathbf{V}_{-i} \mathbf{q}_{i-1} = (\mathbf{V}_{-i} \mathbf{V}_{-i+1}) \mathbf{q}_{i-2} \\ &= \cdots = (\mathbf{V}_{-i} \cdots \mathbf{V}_{-1}) \nabla f_k\end{aligned}$$

Luego

$$\alpha_i = \rho_{-i} \mathbf{s}_{-i}^T \mathbf{q}_{i-1} = \cdots = \rho_{-i} \mathbf{s}_{-i}^T (\mathbf{V}_{-i+1} \cdots \mathbf{V}_{-1}) \nabla f_k$$

## Algoritmo L-BFGS

Por qué trabaja?

- Calculando  $\mathbf{r}$ .

$$\mathbf{r}_m = \mathbf{H}_{-m} \mathbf{q}_m = \mathbf{H}_{-m} (\mathbf{V}_{-m} \cdots \mathbf{V}_{-1}) \nabla f_k$$

- Por otro lado

$$\begin{aligned} \mathbf{r}_i &= \mathbf{r}_{i+1} + \mathbf{s}_{-i} (\alpha_i - \rho_{-i} \mathbf{y}_{-i}^T \mathbf{r}_{i+1}) \\ &= (I - \mathbf{s}_{-i} \rho_{-i} \mathbf{y}_{-i}^T) \mathbf{r}_{i+1} + \mathbf{s}_{-i} \alpha_i \\ &= \mathbf{V}_{-i}^T \mathbf{r}_{i+1} + \mathbf{s}_{-i} \alpha_i \end{aligned}$$

## Algoritmo L-BFGS

Por qué trabaja?

- Comenzando por  $\mathbf{r}_1$  y usando la recursividad anterior y la formula para  $\alpha_i$

$$\begin{aligned}\mathbf{r}_1 &= \mathbf{V}_{-1}^T \mathbf{r}_2 + \mathbf{s}_{-1} \rho_{-1} \mathbf{s}_{-1}^T \nabla f_k \\ &= (\mathbf{V}_{-1}^T \mathbf{V}_{-2}^T) \mathbf{r}_3 + \mathbf{V}_{-1}^T \mathbf{s}_{-2} \rho_{-2} \mathbf{s}_{-2}^T \mathbf{V}_{-1} \nabla f_k + \mathbf{s}_{-1} \rho_{-1} \mathbf{s}_{-1}^T \nabla f_k \\ &= \dots \\ &= (\mathbf{V}_{-1}^T \mathbf{V}_{-2}^T \dots \mathbf{V}_{-m}^T) \mathbf{H}_{-m}^0 (\mathbf{V}_{-1} \mathbf{V}_{-2} \dots \mathbf{V}_{-m}) \nabla f_k \\ &\quad + \dots + \\ &\quad + \mathbf{V}_{-1}^T \mathbf{s}_{-2} \rho_{-2} \mathbf{s}_{-2}^T \mathbf{V}_{-1} \nabla f_k \\ &\quad + \mathbf{s}_{-1} \rho_{-1} \mathbf{s}_{-1}^T \nabla f_k \\ &= \mathbf{H}_k \nabla f_k\end{aligned}$$

## Algoritmo L-BFGS

---

### Algorithm 6 Algoritmo L-BFGS

---

```
1: for ( $i = 1, 2, \dots$ ) do
2:   Seleccionar  $\mathbf{H}_{-m}^0$ 
3:   Calcular  $\mathbf{d}_k = -\mathbf{H}_k \nabla f_k$ , usando el algoritmo anterior de
     'Limited Memory'
4:   Calcular  $\alpha_k$  usando búsqueda en línea.
5:    $\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$ 
6:   if  $k > m$  then
7:     Eliminar la primera pareja  $\{\mathbf{s}_{k-m}, \mathbf{y}_{k-m}\}$ 
8:   end if
9:   Calcular y Guardar  $\{\mathbf{s}_k = \mathbf{x}_{k+1} - \mathbf{x}_k, \mathbf{y}_k = \nabla f_{k+1} - \nabla f_k\}$ 
10: end for
```

---